Benchmark + Baseline 验收目标矩阵

v08：完成后才允许关闭 Benchmark+Baseline 验收

文档性质。这是一份完整的目标规格和验收合同，不是结果预测，也不是正式论文结果表。后续必须用真实运行、原始事件、独立恢复、冻结收据和 v006 逐项评分表填充。只有真实证据、独立评分和双人复核都完成，项目才可以关闭 Benchmark+Baseline 验收；“符合某几个均值”不构成关闭。

旧版 v07 只作为实测分布锚点保留在 `versions/v07_20261008/`，不向候选方法继承均值、区间或胜率。

1. 关闭条件：先过硬门，再过三门

层级	必须满足的条件	关闭含义
硬条件 H	H1–H10 全部 PASS；任一 FAIL 直接 HOLD，UNKNOWN 不能按 PASS 处理。	真值、信息公平、冻结、恢复链没有硬伤。
评分 B	B1–B8 每项 ≥ 3；B9–B15 每项 ≥ 2 且不得为 0；总分 $\geq 49/60$。	benchmark/baseline 的细项证据达到内部加严线。
Gate A	Gate-A1–Gate-A4 各 ≥ 3，总分 $\geq 12/16$；H1–H4 PASS。	Benchmark 选型和 routing protocol 闭合。
Gate B	Gate-B1–Gate-B4 各 ≥ 3，总分 $\geq 12/16$；每个主 baseline 有同合同 raw run 和 recovery。	Baseline 选型、保真和公平比较闭合。
Gate C	Gate-C1–Gate-C4 各 ≥ 3，总分 $\geq 12/16$；E1–E5 无缺口，E6 完成 Stage-B。	实验矩阵、结果方向、成本、失败和不确定性闭合。

最终判定：H、B、Gate-A、Gate-B、Gate-C 全部通过，并提交独立的 v006 评分表、双人复核和当前论文的 Stage-B untouched confirmation 后，Benchmark+Baseline 状态为 **CLOSED**。评分表和复核记录是本 Guide 的最后两个交付物，不是另一个未声明的门。任一顶层门不通过，状态为 **HOLD**，不能用其他门高分抵消。E6 不是把开发集做大，而是方法、菜单、epoch、阈值和 baseline 冻结后的一次性确认；本项目当前目标把 E6 列为必做。

2. Benchmark 合同：公共真值和自建 routing layer 分开

层	本项目必须固定的内容
公共 truth layer	TDC BBB 的公开来源、版本、下载 hash、endpoint 语义和标签生成脚本；duplicate、canonical 冲突、unknown、timeout 和失败规则逐条记录。
Routing layer	分子 x、endpoint、当步 eligible menu A_t、一次只选一个 provider、selected-only 输出、termination/runtime status、反馈延迟 $D \in \{0, 1, 4\}$、release tick、state hash 和下一次决策。
主投稿切片	四个 fresh providers；development 与 157 个 scaffold-disjoint confirmation molecules 分开；33-provider Task36 只作 development，不把 provider 数量当独立证据。
可见信息	选择前只能看声明的 S_t, A_t 和已 release 的 selected outcome；不能看 truth、当前未选输出或 full panel。fit-only warm start 与 evaluator-only control 单独标记。
独立性边界	provider 源码、checkpoint、训练成员、family lineage、许可证和失败语义留 receipt；相关 provider 以 family-macro、exposure 和 joint-error 报告，不假设彼此独立。

两层不能混名：TDC BBB 承担“答案是什么”的公共来源责任；routing layer 承担“在什么信息和时钟下选择工具”的实验协议。论文可以贡献新的 routing protocol，但不能把自建回放层直接称作社区公认 benchmark。

3. Baseline 合同：每个方法回答不同问题

TARGET / NOT RESULTS

方法 / 控制	角色	同合同要求
Random	下界	同 menu、failure/unknown、调用预算和 seed；只回答任务是否有信号。
Fit-only Best Fixed	训练期固定赢家	只用 fit 区完整标签；不读取 confirmation；不能冒充 online。
Retrospective Best Fixed	evaluator-only 控制	可用来显示可达 headroom；不进入可部署排序，不称逐分子 Oracle。
Frozen selector	静态能力控制	与候选共用 feature/menu/prior；自然场景允许成为强基线。
Matched Online-SGD / Replay	最近的普通持续学习对照	同 prior、selected-only feedback、D、update budget、seed 和 compute；是主要现代对照。
Greedy LinUCB	经典在线探索	记录初始化和特征；适配名称显式包含 fit-prior / common-prior。
BayesianRouter-adapted	主要现代后验路由对照（canonical primary）	method_id=`bayesianrouter`；保存论文、源码、版本、prior、适配差异和 raw/recovery。公开跨域数字只作动机。
LinTS-adapted	采样路由 audit-only（除非另行声明为主 baseline）	method_id=`lin_ts_adapted`；同一 selected-only 合同；不能与 BayesianRouter 合并成一个结果行。
MIRA-Relay candidate	目标方法	必须有自己的 Frozen、SGD/Replay、Permutation、机制消融和错误分解。

Baseline 完成定义：名单不等于完成。主 baseline 必须有同一输入/menu/feature/prior/feedback/delay/failure/unknown/budget/seed/compute 合同、真实 raw JSONL、配置和 source hash、独立 recovery，以及失败和成本字段。任何只保留论文均值、只跑 smoke、或无法恢复状态的 baseline 只能列为 audit-only。

TARGET / NOT RESULTS

4. H1–H10 硬条件清单

ID	PASS 条件	直接 HOLD 的情况
H1	truth 来源、版本、标签语义和 hash 固定。	运行时下载未锁版本或来源不可追溯。
H2	duplicate、canonical 冲突、别名和 unknown 规则公开。	按第一行、多数票或模型表现静默清洗。
H3	molecule/scaffold split、confirmation 和 provider training exposure 分开审计。	development/test 或训练成员重叠未披露。
H4	provider 源码、commit、checkpoint、环境和失败语义可追溯。	只有工具名，没有可重现输出。
H5	选择前不读取 truth、未选输出或 full panel。	static full-panel 排序冒充 online。
H6	所有方法共用输入、menu、selected-only 反馈、delay、预算和初始化权限。	candidate 拥有额外标签、warm start 或 compute。
H7	有 canonical、modern nearest、matched control、固定策略和 evaluator-only control。	只和 Random 或过时方法比较。
H8	confirmation 在方法、menu、epoch、阈值和 baseline 冻结后一次性只读。	看 confirmation 后调参或标签回流。
H9	指标、分母、failure/unknown/delay 统计和不确定性开跑前冻结。	出结果后删失败、换指标或改分母。
H10	raw JSONL、config、hash、checkpoint 和独立 verifier 可重算。	只有最终均值或手工表。

每项证据最小格式：文件路径、SHA-256、生成命令、统计脚本和 verifier 版本。没有路径和 hash 的叙述最多记 2 分，不能给 3 或 4 分。

5. B1–B15 评分对象与门槛

TARGET / NOT RESULTS

ID	评分维度	4 分所需的完整证据
B1	truth 权威性	public/primary source、版本/hash、下载清单、脚本、独立核对和 source sensitivity。
B2	标签语义	endpoint/threshold、duplicate、unknown、failure、冲突规则和逐字节标签重生成。
B3	split/独立性	molecule/scaffold、development/confirmation、provider exposure 分层和 overlap audit。
B4	provider lineage	model hash、训练来源、commit、环境、失败、许可证和 deterministic/independent receipt。
B5	任务匹配	输入、menu、action、selected feedback、delay、budget、failure/unknown 的机器校验 contract。
B6	信息与因果公平	visible history/release time 事件证据和能拒绝非法 trace 的 checker。
B7	动态事件覆盖	$D \in \{0, 1, 4\}$、pending queue、selected-only release、failure/pressure 与 scope 边界。
B8	资源/初始化公平	feature、prior、seed、compute、budget、cold/common-warm/online 分层的 independent checker。
B9	baseline 角色完整	Random、fixed、retrospective、Frozen、matched online、现代近邻和目标方法各有问题对应。
B10	baseline fidelity	论文版本、源码 commit、适配差异、license、超参、tuning budget 和数值/单元测试。
B11	provider family correlation	family-macro、pooled、exposure/lineage 分层、paired uncertainty 和敏感性。
B12	metrics/utility	future correctness、error/regret、calls、latency、update、memory、failure/unknown 和 utility。
B13	statistics	seed、paired episode/order、scaffold/family cluster、95% CI/effect、分母和负结果。
B14	experiment coverage	E1–E5 映射 RQ，含机制、边界、成本、停止规则；E6 按 scope 加入。
B15	reproducibility/confirmation	config、命令、环境、GPU、hash、逐事件日志、checkpoint、recovery 和 freeze receipt。

评分锚点：0= 缺失/矛盾/泄漏；1= 只有名单或描述；2= 可运行但审计不完整；3= 合同、原始记录、独立复核齐全；4= 在此基础上有压力或负例、恢复和清楚的 claim scope。通过要求：B1–B8 ≥ 3，B9–B15 ≥ 2 且不得为 0，总分 $\geq 49/60$。

TARGET / NOT RESULTS

6. 实验矩阵与正文交叉映射

最终正文展品	受验收矩阵	必须回答的问题	必须出现的证据
Table 3：任务有效性与主结果	E1 + E2	provider 是否有 headroom；候选与 Frozen/SGD/Replay/Random 怎样比较。	fit/retrospective controls、同合同主 baseline、分母和 raw receipt。
Table 4：source credit / rescue-harm	E2 + E3	收益来自哪些 provider 错误结构；是否有 harmed switch。	correctness bits、rescue/harm/both-wrong、family/scaffold paired effect。
Table 5：prior / 机制消融	E3	full 方法是否胜自己的去模块版本。	同 schedule、同 budget、permutation 和 negative result。
Table 6：delay / pressure	E2 + E4	selected-only delayed feedback 在 $D = 0, 1, 4$ 和受控压力下是否成立。	release clock、pending queue、压力 receipt、每个 delay 的分布。
Table 7：错误、拒答与失败	E4 + E5	什么时候错、什么时候拒答、系统失败如何入账。	failure/unknown/refusal 分母、fallback 仅 diagnostic、不静默变 0/1。
Table 8：成本与恢复	E5	accuracy 以什么 calls、p50/p95、update、memory 和 recovery 代价换来。	端到端计时、异常日志、独立 verifier、break-even。
Table 9：冻结确认（固定 artifact ID）	E6	开发结论能否迁移到 untouched scaffold-disjoint data。	`paper/aamas2027/main.tex#tab:confirmation`；方法/menu/epoch/threshold/baseline freeze、一次性 raw receipt、标签不回流。
Figure 3：dynamic trace	E2 + E4	数据怎样从 terminal 到 pending、release、state update 和下一次 action。	同一个事件 schema；不能只画静态 full panel。

交叉映射规则：正文每个数字必须能回到一个实验 ID、一个 comparator、一个统计单位、一个 raw JSONL 和一个 hash。当前主稿已有 Table 3–8；关闭前必须在固定 artifact ID `paper/aamas2027/main.tex#tab:confirmation` 写入 Table 9，不能用“同等展品”替代，也不能只在文字里口头声明。Table 7 的拒答展示不是生效标准里的 untouched E6，二者不能混名。

7. E1–E6 目标矩阵：做完它才有资格关门

TARGET / NOT RESULTS

实验	必答问题	必须做的比较与分布	通过/停机
E1 任务有效性	provider 是否存在可利用差异和可达 headroom?	Random、fit-only Best Fixed、retrospective control、Frozen；5-fold OOF、joint bits、all-correct/mixed/all-wrong、失败/unknown。	Best Fixed 相对 Random 的 pooled paired 方向为正且 ≥ 3/5 fold；否则 benchmark 先 HOLD。
E2 主比较	delayed selected-only feedback 是否改善未来选择?	candidate 自己的 Frozen、matched SGD/Replay、Greedy LinUCB、BayesianRouter-adapted、Permutation；LinTS-adapted 只有在声明为主 baseline 时才进入主比较；自然和 controlled 分开，报告 mean CI、order/scaffold quantile、strict-win、rescue/harm。	controlled 主 contrast 点估计 ≥ +2.0pp 且 95% paired CI 下界 ≥ +0.5pp；natural 只要求不超出 −1.0pp non-inferiority margin，若宣称自然 superiority 则 CI 下界必须 > 0。
E3 机制消融	结果来自动态 relay 机制而非 backbone、prior 或预算?	full、去 state、去 interface、independent residual、family/provider permutation；同 schedule/budget/seed。	controlled 机制 contrast 点估计 ≥ +1.0pp 且 CI 下界 ≥ 0；若只胜旧 baseline、不胜自身 ablation，机制 claim HOLD。
E4 动态/压力	declared dynamic scope 是否成立?	$D = 0, 1, 4$、pending queue、selected-only release、transient/persistent failure、controlled correctness flip；natural lifecycle/arrival shift 另列。	受控压力 pooled contrast 满足 E2 margin；每个 delay 单独报告，不能把 pooled 正数写成每层都赢；非法提前反馈直接 HOLD。
E5 错误/成本/恢复	方法的收益是否值得代价，失败是否透明?	calls、latency p50/p95、update cost、memory、restart/replay、failure/unknown/refusal、utility/break-even。	selector+update p95 ≤ 2× Frozen 且 ≤ 100 μs（kernel/replay）；这是项目性能目标，不能替代 v006 的 B12/B13/B15。端到端 provider time 单列，任何隐藏 call 或删失败直接 HOLD。
E6 冻结确认	开发结论能否迁移到 untouched data?	固定的 157 个 scaffold-disjoint confirmation molecules；方法、menu、epoch、threshold、baseline 先冻结，一次运行。替换数据集必须另建版本和 ADR，不能在 v08 内替换。	natural 若宣称安全需 CI 下界 ≥ −1.5pp；controlled claim CI 下界 > 0；标签回流、补跑或调参直接 Stage-B FAIL。Stage-A 的 E1–E5 先评分，只有 Stage-A 通过后才打开这一份 confirmation。

TARGET / NOT RESULTS

阈值解释：E2 的 +2.0pp 是 practical margin，不是声称结果；+0.5pp 的 CI 下界是避免只靠点估计；−1.0/ − 1.5pp 是自然场景允许的明确边界。E1 的“3/5 fold”是有效性门槛，不是统计显著性。若真实结果未过对应 claim，只能删除该 claim，不能把同一数字换成另一统计口径继续声称通过。

TARGET / NOT RESULTS

8. 结果分布和误差合同

对象	关门时必须呈现
联合错误	每个 provider 的 correctness bit、all-correct/mixed/all-wrong、family correlation；不能假设 provider 独立。
配对错误	rescue、harm、both-wrong、neutral action change；均值增益不能隐藏错误切换。
统计单位	stream/order、molecule、scaffold、family、fit seed 分开；逐 event 只能作记录，不可直接当独立样本。
到达顺序	若声称 arrival robustness，重新运行完整 adaptive trajectory；报告 128 matched orders 的 mean、paired SD、q025/q975、range 和 strict-win。旧 v07 只作 anchor。
方法相关性	$s^2_{A-B} = s^2_A + s^2_B - 2\,\mathrm{Cov}(A,B)$；共同 order/stream 必须保留 covariance。
失败和未知	runtime failure、unknown、refusal、fallback、timeout 全部入账；fallback 只作诊断，不作为 chemical correctness。
成本	calls、selector/update p50/p95、端到端 latency、memory、restart/recovery 和 utility 同表；kernel-only 与 end-to-end 分开。
重算	raw JSONL、config、source/input/checkpoint hash、独立 verifier 和聚合脚本分离；重算误差在预登记 rounding 内。

禁止继承：候选方法不能继承 v07 的 SD、covariance、win rate 或旧策略的 order 分布。每个新候选有自己的 paired vectors。公开论文中的 LinUCB、LinTS、BayesianRouter 数字只证明方法家族有近期先例，不能作为 BBB 的效果目标。

9. 结果合理性和失败规则

检查	允许的合理关系	不能通过的表现
自然场景	MIRA 可与 Frozen 持平或小幅逊色；若主张自然 superiority 才要求正向 CI。	只因受控压力正向就宣称普遍自然提升。
受控反馈	MIRA 应相对 matched SGD/Replay 有可解释增益，并报告 harmed/rescued。	只胜 Random/弱 adapter，或删掉负 order。
All-wrong	各方法共同保留不可修错误；收益来自 mixed/avoidable strata。	把共同 all-wrong 当作 routing gain。
压力与延迟	分层结果可以不同；pooled 不能冒充每个 D 都赢。	改 release clock、提前看反馈、把 controlled flip 叫自然漂移。
成本与失败	允许准确率/成本 trade-off，但 utility contract 先冻结。	通过静默拒答、隐藏 call、删除 runtime failure 提高分数。
公开结果	只作家族、年代和量级的文献锚点。	把跨任务 accuracy/cost 直接填进 BBB 表。

停止规则：E2 controlled margin、E3 attribution、E5 cost/recovery 或 H1–H10 任一失败时，停止继续调参贴目标；保留负结果并修改 claim 或方法。E1–E6 的目标是让结果可判定，不是逼实验产生预设数字。

TARGET / NOT RESULTS

10. 关闭包和独立评分表：这是验收的一部分

真实实验完成后，必须把以下文件一起提交；缺任何一个，不能写 CLOSED。

文件	必须包含的内容
`closure_scorecard_v08.md`	H1–H10 的 PASS/FAIL、B1–B15 的 0–4 分、Gate-A/B/C 子分数和总分；每格写 evidence path、SHA-256、日志行号、缺口和修复动作。
`closure_review_author.md`	benchmark/data auditor 的独立签名、日期、scope、逐项评分和是否推荐 CLOSED。
`closure_review_replicator.md`	paper/reproducibility auditor 的独立签名、恢复命令、重算差异和是否推荐 CLOSED。
`closure_decision_v08.json`	机器可读的最终状态：`CLOSED` 或 `HOLD`；绑定 Guide、标准、主稿和所有 score/review hash。

两名复核者分差达到 2 分时，先补证据再重评；任一 H 失败、Gate 子项低于 3、B 总分低于 49/60 或 E1–E6 缺 raw/recovery，机器状态只能是 **HOLD**。只有双方都给出 CLOSED，且复核记录引用的证据哈希与表格数字一致，才关闭。

11. 完成后逐项签收

ID	完成条件	签收状态
Gate-A1	公共 truth、版本/hash、endpoint 语义、冲突/unknown 规则和重生成 receipt。	PASS / HOLD
Gate-A2	routing contract 机器校验：menu、selected-only、delay、failure、release、state hash。	PASS / HOLD
Gate-A3	split、scaffold、provider exposure 和 untouched confirmation 隔离审计。	PASS / HOLD
Gate-A4	provider lineage、family correlation、macro/exposure/joint-error 报告。	PASS / HOLD
Gate-B1	baseline role roster 完整，所有主 baseline 各有同合同 raw run。	PASS / HOLD
Gate-B2	输入、反馈、目标、dynamic scope 和适配差异匹配并写清。	PASS / HOLD
Gate-B3	论文/源码/commit/checkpoint/license、adapter test 和 tuning budget 可追溯。	PASS / HOLD
Gate-B4	feature/prior/seed/budget/compute/delay/failure 公平 checker 通过。	PASS / HOLD
Gate-C1	E1–E6 各映射 RQ、正文展品、配置、原始 JSONL 和 hash。	PASS / HOLD
Gate-C2	candidate 与主 baseline 同一 contract，paired vectors 和 recovery 全齐。	PASS / HOLD
Gate-C3	方向、practical margin、自然边界、机制归因、成本和 scope 全符合。	PASS / HOLD
Gate-C4	uncertainty、failure/unknown、负结果、independent recovery、claim scope 全闭合。	PASS / HOLD

TARGET / NOT RESULTS

关闭判定：上述 Gate-A1–Gate-A4、Gate-B1–Gate-B4、Gate-C1–Gate-C4 全部 PASS，同时 H1–H10 PASS、B1–B15 分数达到第 1 节门槛、正文展品和 raw evidence 一一对应，且第 10 节的 scorecard 与双人复核均推荐 CLOSED，状态才写 **CLOSED**。这份 Guide 完成后可以关闭验收；scorecard 和复核是 Guide 的组成部分。

12. 版本、来源和主版隔离

材料	处理规则
Guide v01–v07	全部保留；v07 是固定已查看队列的实测参考，不能继承给未来候选。
Guide v08	本文件是第一版完整 closure target；后续若共同确认修改阈值或范围，另建 v09，不能静默覆盖。
正式论文 main.pdf	不写入 T/B 目标数值；只写真实运行结果，编译和主版提升独立进行。
公开 baseline 结果	存在 `~/work/reasonable_results/pharma_tool_selection_public_baselines_v1/`，只作文献锚点。
证据归档	`experiments/logs/` 保存 raw/config/failure/recovery；缺少 source/hash 的表格不能签收。

一句话验收标准：当且仅当真实 benchmark、真实 baseline、E1–E6、三门评分、硬条件、分布/失败/成本、独立恢复和双人 scorecard 全部按本矩阵签收，Benchmark+Baseline 才能关闭；任何目标数值在此之前都只是 T，不是 M。